

五篇大语言模型安全智能体文献分析

面向毕业设计课题的文献研读笔记

一、引言

本文档面向毕业设计课题“基于黑板架构与多引擎协作的 Web 安全自动推理系统的设计与实现”，选取五篇与本课题直接相关的大语言模型安全智能体文献进行研读，逐篇归纳其主干内容、中心思想与关键技术细节，并在文末给出横向对比和综合启示。五篇文献分别覆盖 CTF 漏洞挖掘训练环境、多代理自动化渗透测试、多智能体协作 CTF 求解、多智能体与检索增强的渗透测试框架，以及面向 CTF 解题的智能体系统，与本课题“多引擎并行、黑板协作、证据驱动完成判定”的主线高度一致。

文献信息说明：外文文献的题名、作者、年份经 arXiv 官方页面或 Crossref 核验；两篇中文文献的题名、作者、刊名、年份、期号经万方数据检索页核验，卷号与起止页码尚未从公开渠道取到，著录为“年(期)”简式，交稿前建议在知网或万方补全。

二、五篇文献概览

编号	文献	类型	核心主题	与课题衔接
文献一	CTF-Dojo (arXiv 2025)	训练环境与基准	可执行环境 + 可验证反馈训练 LLM 漏洞挖掘智能体	容器化执行与证据验证思想
文献二	张红伟等 (网络安全技术与应用 2026)	应用框架	LLM 构造多代理系统模拟渗透团队协作	多 Worker 协作与调度
文献三	D-CIPHER (arXiv 2025)	多智能体框架	Planner-Executor 异构协作求解 CTF	Coordinator 与 Worker 分层
文献四	江颀等 (自动化学报 2026)	多智能体 + RAG	多智能体协同渗透，应对路径偏移与幻觉	分类闸门与工具域锁定
文献五	CTFAgent (JISA 2026)	智能体系统	面向 CTF 挑战求解的 LLM 智能体	同类课题定位与对比

三、文献一：CTF-Dojo——训练语言模型智能体挖掘漏洞

文献信息：ZHUO T Y, WANG D M, DING H T, 等. Training language model agents to find vulnerabilities with CTF-Dojo[EB/OL]. (2025-08-25)[2026-09-08]. <https://arxiv.org/abs/2508.18370>.

主干内容：该文提出 CTF-Dojo，这是首个面向大语言模型智能体训练的大规模可执行 CTF 环境，包含 658 道完整可用、容器化封装、保证可复现的 CTF 风格漏洞挖掘题目。为降低环境构建成本，论文配套提出 CTF-Forge 自动化流水线，可在数分钟内把公开的题目构件转换为可直接执行的环境，替代以往需要数周人工配置的做法。训练方面，作者仅使用 486 条经过执行验证的高质量解题轨迹训练智能体，即在 InterCode-CTF、NYU CTF Bench、Cybench 三个竞争性基准上取得最高 11.6 个百分点的绝对提升；最优的 32B 开源权重模型达到 31.9% 的 Pass@1，创造了新的开源模型最优水平，并可与 DeepSeek-V3-0324、Gemini-2.5-Flash 等前沿模型相比肩。

中心思想：论文的核心论断是：可执行环境与可验证反馈闭环是提升语言模型智能体能力的关键，其价值大于单纯的训练数据规模。CTF 类任务天然具有“执行后可知对错”的验证特性，适合作为可执行智能体学习的通用基准，从而在不依赖昂贵闭源系统的情况下训练出高性能的自动化漏洞挖掘智能体。

关键技术细节：

- 环境工程：658 道题目全部容器化，保证运行环境可复现、可扩展，解决了此前执行环境稀缺且难以泛化的问题。
- 自动化流水线 CTF-Forge：将公开构件自动转换为可用执行环境，把人工配置时间从数周压缩到数分钟，支撑环境规模化扩展。
- 数据策略：只用 486 条“经过执行验证”的高质量轨迹训练，突出数据质量筛选而非数据量堆砌。
- 评测方式：以 Pass@1 为指标，在 InterCode-CTF、NYU CTF Bench、Cybench 三个基准上跨模型验证，保证结论可比较。

对本课题的启示：该文为本课题“容器化 Worker 执行边界”和“证据驱动完成判定”提供了直接依据：智能体必须真实执行、以执行结果作为反馈，才能稳定提升解题能力；同时，可复现的执行环境是训练与评估自动化解题系统的基础设施。

四、文献二：基于大语言模型的自动化多代理渗透测试框架

文献信息：张红伟, 王巍, 翟凯智, 等. 基于大语言模型的自动化多代理渗透测试框架[J]. 网络安全技术与应用, 2026(8).

主干内容：该文针对渗透测试手动执行耗时、已有大语言模型渗透测试框架效率较低的问题，提出基于大语言模型的自动化多代理渗透测试框架。其基本思路是由大语言模型构造多代理系统，模拟人类渗透测试团队的协作流程，将侦察、扫描、利用等环节交由不同代理协同完成，从而有效缓解此前方法效率低下和依赖人工干预的问题。论文关键词覆盖大语言模型、多代理、扫描、渗透测试，属于工程应用型研究。

中心思想：该文主张“用多代理模拟红队分工协作”替代单模型串行推理：渗透测试天然是多角色、多阶段的团队任务，多代理协作比单个大模型逐轮推理更贴近真实测试流程，也更容易提升效率与覆盖面。

关键技术细节：

- 多代理系统：由大语言模型动态构造多个代理，分别承担渗透测试流程中的不同职责。
- 协作流程建模：以人类渗透测试团队的分工方式为模板组织代理间的协作。
- 自动化目标：减少人工干预，把扫描与渗透动作纳入框架级自动化流程。

说明与启示：该文发表于普刊《网络安全技术与应用》，公开摘要未披露具体代理数量、调度算法与评测数据，技术细节深度有限，论文分析以公开摘要与关键词为基础。对本课题的启示在于验证了“多代理分工 + 自动化协作”方向在渗透测试领域的实用性，与本课题多 Worker 池与 WorkerManager 调度思想同源，可作为工程应用层面的背景文献。

五、文献三：D-CIPHER——动态协作的多智能体 CTF 求解框架

文献信息：UDESHI M, SHAO M H, XI H R, 等. D-CIPHER: dynamic collaborative intelligent multi-agent system with planner and heterogeneous executors for offensive security[EB/OL]. (2025-02-15)[2026-09-08]. <https://arxiv.org/abs/2502.10931>.

主干内容：D-CIPHER 是面向 CTF 协作求解的多智能体框架。论文指出，早期单智能体方案只有单一“推理-行动”反馈回路，难以处理复杂 CTF 任务；受真实 CTF 比赛中专家团队协作的启发，D-CIPHER 将多个承担不同角色的智能体与动态反馈回路结合。其核心是 Planner-Executor 架构：一个 Planner 智能体负责整体问题求解与任务分配，多个异构 Executor 智能体分别执行具体任务；此外引入 Auto-prompter 智能体，自动生成与题目高度相关的初始提示，改善推理起点。评估方面，论文在 NYU CTF Bench 达到 22.0%、Cybench 达到 22.5%、HackTheBox 达到 44.0%，比此前工作提升 2.5 到 8.5 个百分点；并首次将 NYU CTF Bench 题目人工映射到 MITRE ATT&CK，验证其解决的安全技术数量比此前工作多 65%，进攻性安全能力更强。

中心思想：复杂安全任务需要“规划与执行分离、异构角色协作”：由 Planner 统一规划，由异构 Executor 分工执行，并通过动态反馈持续修正，能够显著超越单智能体循环；同时，评估不应只看解题数，还应映射到 ATT&CK 等技术维度，以体现真实进攻能力。

关键技术细节：

- Planner-Executor 两级架构：Planner 负责全局规划，Executor 负责具体任务执行，职责清晰、可扩展。
- 异构 Executor：多个执行器能力与分工不同，适合并行处理不同类型的子任务。
- Auto-prompter：自动生成高相关初始提示，改善智能体的推理起点。
- 动态反馈回路：执行结果持续回流到规划层，支持多轮修正。
- 评测方法论：多基准评测 + MITRE ATT&CK 映射，兼顾解题率与技术覆盖度。

对本课题的启示：D-CIPHER 的 Planner-Executor 分层与本课题“Coordinator/Reason 规划 + 多 Worker 引擎执行”的结构几乎一一对应，可作为论文架构对比与参考文献；其 ATT&CK 维度评估方法也可迁移到本课题的完成判定与能力评估设计中。

六、文献四：基于大语言模型的多智能体自动渗透测试框架构建与评估

文献信息：江颀, 王豪, 李明达, 等. 基于大语言模型的多智能体自动渗透测试框架构建与评估[J]. 自动化学报, 2026(4).

主干内容：该文发表于《自动化学报》。论文指出，渗透测试是主动安全评估的重要手段，但传统方式高度依赖专家经验与人工操作，复杂且耗时；基于大语言模型的渗透测试智能体能够在测试环境中生成并调整策略，具有更强的创新性和适应性，但在实际运行中存在两类典型失败：测试路径偏移与大语言模型“幻觉”，二者会导致渗透测试任务中断或失败。针对这一问题，论文提出一个基于大语言模型的多智能体渗透测试框架，并引入检索增强生成机制（RAG）为智能体补充相关知识，最后对框架进行了构建与评估。

中心思想：该文的核心主张是：仅靠单个大语言模型生成渗透动作是不够的，必须用多智能体协同控制测试路径，并用外部知识检索抑制幻觉，才能把 LLM 渗透测试从“能生成”推进到“可持续、可收敛”。

关键技术细节：

- 多智能体协同：将渗透测试流程拆分为多个智能体分工承担，控制系统性偏差。
- 检索增强生成：引入 RAG 为模型补充领域知识，缓解知识滞后与幻觉问题。
- 问题导向设计：明确针对“路径偏移”和“幻觉”两类失败进行机制设计。
- 构建与评估并重：论文包含框架构建与实验评估两个环节。

说明与启示：万方公开摘要仅展示论文前半部分，具体智能体数量、RAG 实现方式与评测指标需以全文为准，建议从知网或万方获取全文后补充。该文与本课题“分类闸门 + 工具域锁定”防止路径漂移、以及“黑板事实 + 证据引用”抑制幻觉的设计思路一致，是中文核心期刊层面的重要支撑文献。

七、文献五：CTFAgent——面向 CTF 挑战求解的大语言模型智能体

文献信息：ZOU Y W, LIU J, FAN W J. CTFAgent: an LLM-powered agent for CTF challenge solving[J]. Journal of Information Security and Applications, 2026, 96: 104305. <https://doi.org/10.1016/j.jisa.2025.104305>.

主干内容：该文发表于 Elsevier 期刊《Journal of Information Security and Applications》（信息安全与应用杂志），研究面向 CTF 挑战求解的大语言模型智能体 CTFAgent。由于该文为付费访问，公开渠道仅能核验题名、作者、期刊、卷期与文章号，未获取到公开摘要；以下归纳严格基于题名与期刊定位：论文关注如何让大

语言模型智能体自主完成 CTF 挑战求解，属于“LLM 智能体 + 网络安全基准求解”方向，与 CTF-Dojo、D-CIPHER 属于同一研究域。具体的方法设计、数据集、评测指标需要从学校图书馆获取全文后补充。

中心思想：基于题名与选题定位，该文的核心问题是把 CTF 解题建模为大语言模型智能体的端到端任务，探索智能体在安全推理任务中的自主求解能力；其结论与贡献细节待全文补充。

关键技术细节：

- 待补充：论文全文位于付费墙后，智能体架构、工具调用方式、评测基准与结果均需以全文为准。
- 获取建议：可通过学校图书馆的 ScienceDirect 全文库下载该文（DOI: 10.1016/j.jisa.2025.104305），下载后即可补全本节。

对本课题的启示：该文献可作为课题“LLM 智能体求解 CTF”方向的期刊级支撑，与 arXiv 来源的文献形成互补；建议在论文中将其与 CTF-Dojo、D-CIPHER 一起作为同类研究对比。

八、五篇文献对比与综合启示

文献	主要方法	定位	关键数据	核心主张
CTF-Dojo	可执行环境 + 轨迹训练	训练与基准	658 题、486 轨迹、31.9% Pass@1	执行反馈优先
张红伟等	多代理模拟团队协作	应用框架	未披露详细指标	多代理分工
D-CIPHER	Planner-Executor 协作	多智能体框架	NYU 22.0% / Cybench 22.5% / HTB 44.0%	规划与执行分离
江颀等	多智能体 + RAG	多智能体框架	以全文为准	路径控制与知识增强
CTFAgent	LLM 智能体求解 CTF	智能体系统	以全文为准	端到端自主求解

综合启示

- 执行反馈是能力的来源：CTF-Dojo 证明“可执行环境 + 验证反馈”训练能显著提升智能体能力，本课题应坚持容器化执行与证据驱动完成判定，不依赖模型自述完成。

- 规划与执行分离是稳定架构：D-CIPHER 与江颀等的工作都表明 Planner 与异构执行者分离、多智能体分工能减少路径漂移，本课题的 Coordinator-Reason 与多 Worker 引擎结构与之同构。
- 外部知识能抑制幻觉：江颀等引入 RAG、D-CIPHER 引入 Auto-prompter，本课题的模板召回与黑板事实注入可视为同类机制。
- 评测要兼顾结果与过程：D-CIPHER 用 ATT&CK 映射评估能力覆盖，本课题可用“有效路线数、重复请求数、证据完整度”等指标补充完成率评估。
- 中文工程文献的价值：张红伟等代表多代理渗透的应用实践，可作为工程背景与对比；CTFAgent 需获取全文后补全细节，建议纳入论文参考文献并重点阅读。

九、资料来源与待办说明

- CTF-Dojo 与 D-CIPHER 的摘要来自 arXiv 官方页面，元数据经核验。
- 张红伟等与江颀等的题名、作者、刊名、年份、期号来自万方数据检索页；两篇的卷号与起止页码待登录知网/万方后补全。
- CTFAgent 的元数据来自 Crossref/OpenAlex，全文与摘要位于付费墙后，待从学校图书馆获取后补全“主干内容”与“关键技术细节”。
- 本报告为文献研读笔记，供毕业设计论文撰写使用；引用时请按学校规范统一标点与著录细节。